

Análisis de Modelos de Series Temporales Univariantes: Modelos ARMA

Econometría Aplicada

Pablo Monrocle Arribas

NOTAS DE TRABAJO/ WORKING NOTES

Por favor, no citar ni distribuir sin permiso del autor.

12/2025

Índice

1. Introducción al análisis de series temporales univariantes	2
2. Identificación de los principales procesos estocásticos	4
2.1. Procesos estacionarios de Ruido Blanco	4
2.2. Procesos estacionarios de Media Móvil de orden q	5
2.3. Procesos estacionarios Autorregresivos de orden p	9
3. Descomposición de Wold	12
4. Estimación	15
5. Diagnóstico	17
6. Predicciones	18
7. Aplicación práctica con datos reales	19
7.1. Contexto	19
7.2. Serie temporal de ocupados	21
7.3. Serie temporal de parados	26
7.4. Serie temporal de tasa de paro	30
Conclusión	30
Bibliografía	31
A. El contraste de raíz unitaria de Dickey-Fuller	32

Resumen

Este artículo presenta una primera aproximación breve y con vocación didáctica pero rigurosa al análisis de modelos estadísticos de series temporales centrados en la media condicional. Concretamente, se trata la metodología de Box y Jenkins (1976) de predicción de series temporales univariantes basada en las etapas de identificación, estimación, diagnóstico y predicción. Primero, se hace una breve introducción con la intención de justificar el uso de modelos estadísticos de series temporales univariantes. En segundo lugar, identificamos los principales procesos estocásticos, que son los procesos estacionarios de Ruido Blanco, Media Móviles $MA(q)$ y Autorregresivos $AR(p)$. En tercer lugar, utilizamos el teorema de descomposición de Wold (1954) para obtener el modelo $ARMA(p, q)$. En cuarto lugar, se lleva a cabo la estimación de los parámetros del proceso estocástico identificado. En quinto lugar, la diagnosis de los residuos del modelo estimado para verificar su validez. En sexto lugar, se lleva a cabo la predicción en base al modelo estimado identificado y previamente validado. En séptimo y último lugar, se lleva a cabo una aplicación práctica de esta metodología a tres series del mercado laboral: ocupados, parados y la tasa de paro, calculada a partir de las dos anteriores. El análisis se realiza mediante el modelo $SARIMAX(p, d, q) \times (P, D, Q, S)$ para cada serie respectivamente. Es fundamental destacar que el objetivo no es solo la predicción, sino la contextualización de la evolución de estas series, utilizando conocimiento experto para interpretar su significado económico.

1. Introducción al análisis de series temporales univariantes

La principal característica de las series temporales es que los datos tienen un orden y ese orden influye en la dependencia de los datos. Los datos en los modelos clásicos de inferencia estadística, y generalmente en los modelos de regresión con datos de sección cruzada, son independientes en el momento de cada observación¹. Sin embargo, en los modelos de series temporales el tiempo existe y su influencia la determina la relación cronológica de los datos. En estos modelos tratamos de forma diferente la media y la varianza porque ponemos el énfasis sobre la tendencia y la varianza condicional, a través de los valores de la covarianza, en el que sí influye el grado de separación de los distintos instantes, es decir, en el que sí influye el tiempo.

Dentro de los modelos de series temporales podemos distinguir dos tipos de series: aquellas generadas de datos replicables y aquellas generadas de datos no replicables.

Es común en las ciencias técnicas disponer de datos que se pueden replicar, es decir, tenemos múltiples series referentes a un mismo objeto de estudio. Por ejemplo, el peso de los recién nacidos durante sus primeros 25 meses de vida. Con esta muestra se pueden obtener para cada observación medidas de posición, como los percentiles, y conocer si el peso de un bebé en comparación con el resto, para un mismo mes, está en el promedio de la población. De esta manera, conoceríamos la distribución de la población a partir del vector de pesos para cada mes y, si la muestra es lo suficientemente grande, podríamos aproximar la distribución de ciertos estadísticos mediante una normal (Teorema central del límite). Considerando además su desviación con respecto a la media acumulada de sí mismo y respecto a los demás, podríamos saber que el valor de y_{t+1} , condicionado a su historial de pesos $(y_1, \dots, y_t)$ y tomando como referencia la distribución estimada a partir del resto de bebés, se distribuye como una normal condicionada y, por tanto, que el vector $\mathbf{Y}_{25}$ se distribuye como una normal multivariante con media $\boldsymbol{\mu}_{1:25}$ y matriz de varianzas-covarianzas $\boldsymbol{\Gamma}_{25}$, es decir, $\mathbf{Y}_{25} \sim \mathcal{N}_{25}(\boldsymbol{\mu}_{1:25}, \boldsymbol{\Gamma}_{25})$. La estimación de los valores estaría hecha a efectos prácticos:

¹Véase el esquema de estadística aplicada que descompone la disciplina en tres ramas principales —estadística descriptiva, estadística inferencial y aprendizaje estadístico— y que puede encontrarse en la página de inicio del blog del autor.

$$\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_{25} \end{pmatrix} \sim \mathcal{N}_{25} \left[\begin{pmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_{25} \end{pmatrix}; \begin{pmatrix} \sigma_0^2 & \sigma_{0,1}^2 & \cdots & \sigma_{0,25}^2 \\ \sigma_{1,0}^2 & \sigma_1^2 & \cdots & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{25,0}^2 & \cdots & \cdots & \sigma_{25}^2 \end{pmatrix} \right] \quad (1)$$

Normalmente en las ciencias sociales y particularmente en la economía no es así, dado que se dispone de una serie de datos temporales para una única variable, como por ejemplo el Producto Interior Bruto (PIB), el Índice de Precios al Consumidor (IPC), el Índice de Producción Industrial (IPI), la cotización bursátil del conjunto de 500 empresas más grandes de Estados Unidos (S&P 500), la cotización diaria del precio del petróleo (Brent), el rendimiento de los bonos de deuda pública de EEUU para un horizonte de 10 años (US10Y) o el índice de confianza del consumidor (PMI), entre otros².

Para solventar este problema estimamos los parámetros mediante un modelo y, para reducir el número de parámetros a estimar $-1 + \frac{T(T+1)}{2}$ en el caso de (1)–, establecemos restricciones de estacionariedad para satisfacer el principio de ergodicidad en el que se basa toda esta metodología. Una de las restricciones es suponer que la media del conjunto de datos es constante y común, en vez de haber una media para cada observación:

$$E[y_t] = \mu \quad \forall t \quad (2)$$

Otra de las restricciones es suponer homocedasticidad, es decir, que el valor de la varianza de los datos es constante:

$$\text{Var}[y_t] = \sigma^2 \quad (3)$$

La última de las restricciones es suponer que la covarianza entre dos variables aleatorias solo depende de la distancia entre ambas. De forma que la covarianza entre t y $t-k$ para los distintos k es igual:

$$\text{cov}(y_t, y_{t-k}) = \text{cov}(y_l, y_{l-k}) \quad \forall l, k, t \quad (4)$$

Con estas restricciones conseguimos reducir el número de parámetros a estimar de $1 + \frac{T(T+1)}{2}$ a $T+1$, compuesto por uno de la media común más T parámetros distintos de la matriz de varianzas-covarianzas compuesto por la varianza común (diagonal principal) y por las demás covarianzas (sucesivas subdiagonales):

$$\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_T \end{pmatrix} \sim \mathcal{N}_T \left[\begin{pmatrix} \mu \\ \mu \\ \vdots \\ \mu \end{pmatrix}; \begin{pmatrix} \sigma^2 & \gamma_1 & \gamma_2 & \cdots & \gamma_{T-1} \\ \gamma_1 & \ddots & \ddots & \ddots & \vdots \\ \gamma_2 & \ddots & \ddots & \ddots & \gamma_2 \\ \vdots & \ddots & \ddots & \ddots & \gamma_1 \\ \gamma_{T-1} & \cdots & \gamma_2 & \gamma_1 & \sigma^2 \end{pmatrix} \right] \quad (5)$$

²También encontramos otras series temporales univariantes más enfocadas en negocio y finanzas e investigación operativa, como el tráfico diario en una página web, la evolución en el tiempo de la cantidad demandada de un producto o los costes asociados de la compra de materia prima a un proveedor mayorista.

Cuando se cumplen estos supuestos obtenemos un modelo estacionario en sentido débil³. De manera que diremos que cada y_t es un vector de variables aleatorias indexadas en el tiempo. En este tipo de procesos, las distribuciones marginales (que pueden adoptar desde una distribución continua como la normal hasta una distribución discreta como la binomial) no es necesario que sean idénticas en todas las observaciones, sino que basta con que la media y la varianza sean constantes a lo largo del tiempo.

Generalmente, una serie temporal de un indicador económico no suele ser estacionaria, ya que el vector de variables $\mathbf{Y}_T$ puede presentar tendencia (media no constante) y/o heterocedasticidad (varianza no constante). Por esta razón, es común transformar la serie para obtener estacionariedad en sentido débil aplicando diferenciación regular cuando la tendencia es estocástica, y/o diferenciación estacional cuando hay patrones de estacionalidad. Una vez obtenida la predicción en la serie transformada, se aplica la operación inversa para recuperar los valores originales.

2. Identificación de los principales procesos estocásticos

En el análisis estadístico de series temporales existen tres tipos fundamentales de procesos estocásticos: los procesos estacionarios de ruido blanco, los procesos estacionarios de media móvil de orden q y los procesos estacionarios autorregresivos de orden p .

2.1. Procesos estacionarios de Ruido Blanco

Los procesos de Ruido Blanco (o *White Noise* en inglés)⁴ consisten en un vector de observaciones y_t que se comporta como una variable aleatoria que son entre sí independientes e idénticamente distribuidas (*i.i.d*):

$$y_t = \varepsilon_t, \quad \varepsilon_t \xrightarrow{i.i.d} (u, \sigma^2) \quad (6)$$

Un ejemplo típico de una variable aleatoria discreta *i.i.d* es una sucesión de Bernoulli, $y_t \sim \text{Bernoulli}(p)$, y en su defecto, cuando $n > 1$, la sucesión Binomial, $y_t \sim \text{Binomial}(n, p)$. En este sentido, podemos decir que se cumple que es un proceso estacionario en sentido fuerte, dado que la estructura de varianzas conjunta es la misma que la individual frente a desplazamientos temporales en cada una de las observaciones, porque son independientes. Ahora bien, que un proceso sea ruido blanco (RB) no implica necesariamente que sea gaussiano. El ruido blanco gaussiano (RBG) es solo un caso particular. Por tanto, podemos decir que el proceso de ruido blanco es gaussiano cuando, además, se comporta como una distribución normal:

$$y_t \xrightarrow{i.i.d} \mathcal{N}(0, \sigma^2) \quad (7)$$

En ambos casos, (6) y (7), la distancia entre las observaciones no influye ni aporta ninguna información, dado que los datos son independientes y, por ende, no tienen estructura temporal.

³Los procesos estacionarios en sentido fuerte son matemáticamente más consistentes, pero desde el punto de vista práctico no lo son, porque asumen que todas las distribuciones son iguales, y cuando solo disponemos de una única variable eso no tiene trazabilidad. En estos procesos se asume que todas las funciones de densidad para cada instante t tienen que ser la misma y que, cogiendo un subconjunto de instantes cualesquiera, su función de densidad conjunta tiene que ser la misma. Esto implica que las covarianzas sean todas las mismas.

⁴El proceso de ruido blanco que presentamos aquí es en sentido fuerte. A lo largo del texto, siempre que nos refiramos a un proceso de ruido blanco, ya sea gaussiano o no, es en sentido fuerte.

2.2. Procesos estacionarios de Media Móvil de orden q

En los procesos de Media Móvil de orden q –MA(q)– el valor actual de la serie depende de una combinación lineal de errores pasados que se distribuyen como una normal o ruido blanco gaussiano:

$$y_t = c + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \cdots + \theta_q \varepsilon_{t-q}, \quad \text{donde } \varepsilon_t \sim RBG(0, \sigma_\varepsilon^2) \quad (8)$$

Imaginemos el estado de ánimo actual de una persona $-y_t-$. Esta se ve afectado por eventos imprevistos recientes $-shocks-$ pero no tiene una dependencia directa del estado de ánimo que tenía en días anteriores. Generalmente, esta persona tiene un nivel de humor normal (c). Sin embargo, los eventos diarios alteran ese estado. El término ε_t es el evento inesperado de hoy. Puede ser negativo, como darte cuenta de que has olvidado las llaves de casa o derramar el café en la ropa antes de ir al trabajo ($\varepsilon_t < 0$). O puede ser positivo, como recibir un cumplido en el trabajo o darte cuenta que has cobrado la nomina mensual ($\varepsilon_t > 0$). El término ε_{t-1} fue el *shock* de ayer. Quizás ayer perdiste el autobús y llegaste tarde, lo que te causó un bajo anímico. En un modelo MA, tu estado anímico de hoy (y_t) se explica por tu estado de ánimo cotidiano (c), el fastidio de haber olvidado las llaves hoy (ε_t) y quizás un residuo de la frustración de ayer por perder el autobús ($\theta_1 \varepsilon_{t-1}$). La característica clave es que tu estado de ánimo no tiene memoria de sí mismo. Aunque ayer tuvieras un día fantástico, hoy puedes levantarte con el pie izquierdo por un pequeño tropiezo. Tu humor se reinicia a su nivel normal (c) y solo se ve modificado por estos imprevistos recientes. Después de q días (probablemente uno o dos en este caso), el recuerdo de haber derramado el café ya no tiene ningún efecto en tu estado de ánimo actual.

Sabemos que es un proceso estacionario porque, de las propiedades de estacionariedad, sabemos que la suma de dos procesos estacionarios es estacionaria. Esto lo podemos comprobar calculando la esperanza, la varianza y la auto-covarianza y comprobando que cumplan las propiedades (2), (3) y (4). En cuanto a la esperanza:

$$\begin{aligned} E[y_t] &= E[c + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \cdots - \theta_q \varepsilon_{t-q}] \\ &= E[c] - E[\varepsilon_t] - \theta_1 E[\varepsilon_{t-1}] - \theta_2 E[\varepsilon_{t-2}] - \cdots - \theta_q E[\varepsilon_{t-q}] = E[c] = c \end{aligned} \quad (9)$$

La esperanza es constante y se cumple el supuesto (2) de los procesos estacionarios en sentido débil. En cuanto a la varianza:

$$\begin{aligned} \text{Var}[y_t] &= \text{Var}[c + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \cdots - \theta_q \varepsilon_{t-q}] \\ &= E[(c + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \cdots - \theta_q \varepsilon_{t-q}) - E[y_t]]^2 \\ &= E[(c + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \cdots - \theta_q \varepsilon_{t-q} - c)^2] \end{aligned} \quad (10.1)$$

donde la expresión última:

$$\begin{aligned} &E[(\varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \cdots - \theta_q \varepsilon_{t-q})^2] \\ &= E[\varepsilon_t^2 + (\theta_1 \varepsilon_{t-1})^2 + (\theta_2 \varepsilon_{t-2})^2 + \cdots + (\theta_q \varepsilon_{t-q})^2 - 2\theta_1 \varepsilon_t \varepsilon_{t-1} - 2\theta_2 \varepsilon_t \varepsilon_{t-2} - \cdots - 2\theta_q \varepsilon_t \varepsilon_{t-q} \\ &\quad + 2\theta_1 \theta_2 \varepsilon_{t-1} \varepsilon_{t-2} + 2\theta_1 \theta_3 \varepsilon_{t-1} \varepsilon_{t-3} + \cdots + 2\theta_1 \theta_q \varepsilon_{t-1} \varepsilon_{t-q} + \cdots + 2\theta_{q-1} \theta_q \varepsilon_{t-(q-1)} \varepsilon_{t-q}] \end{aligned} \quad (10.2)$$

de manera que, generalizando el producto cruzado, obtenemos:

$$\begin{aligned}
& E \left[\varepsilon_t^2 + (\theta_1 \varepsilon_{t-1})^2 + (\theta_2 \varepsilon_{t-2})^2 + \cdots + (\theta_q \varepsilon_{t-q})^2 - 2 \sum_{i=1}^{q-1} \sum_{j=i+1}^q \theta_i \theta_j \varepsilon_{t-i} \varepsilon_{t-j} \right] \\
&= E[\varepsilon_t^2] + \theta_1^2 E[\varepsilon_{t-1}^2] + \theta_2^2 E[\varepsilon_{t-2}^2] + \cdots + \theta_q^2 E[\varepsilon_{t-q}^2] - 2 \sum_{i=1}^{q-1} \sum_{j=i+1}^q \theta_i \theta_j E[\varepsilon_{t-i} \varepsilon_{t-j}] \\
&= \text{Var}(\varepsilon_t) + \theta_1^2 \text{Var}(\varepsilon_{t-1}) + \theta_2^2 \text{Var}(\varepsilon_{t-2}) + \cdots + \theta_q^2 \text{Var}(\varepsilon_{t-q}) - 0 \\
&= \sigma_\varepsilon^2 + \theta_1^2 \sigma_\varepsilon^2 + \theta_2^2 \sigma_\varepsilon^2 + \cdots + \theta_q^2 \sigma_\varepsilon^2 = \sigma_\varepsilon^2 (1 + \theta_1^2 + \theta_2^2 + \cdots + \theta_q^2) \quad (10.3)
\end{aligned}$$

La varianza de un proceso MA(q) no depende del tiempo, sino únicamente de la varianza de las innovaciones (σ_ε^2) y de los parámetros ($\theta_1, \dots, \theta_q$). En particular, a partir de (10.3) se obtiene que es estrictamente positiva dada la naturaleza de la varianza. En el caso de que $\sigma_\varepsilon^2 = 0$, entonces no hay perturbaciones aleatorias y el proceso queda degenerado porque $\text{Var}(y_t) = 0$. Para los diferentes valores de σ_ε^2 , la varianza de los residuos va cambiando, pero en todas estas casuísticas la varianza se mantiene constante porque no depende del tiempo y se cumple (3).

En cuanto a la auto-covarianza, lo demostraré con un MA(1), luego con un MA(2) y, finalmente, extrapolaremos su forma generalizada de orden indefinido p . Para un MA(1) la esperanza es constante:

$$E[y_t] = E[c + \varepsilon_t + \theta_1 \varepsilon_{t-1}] = E[c] + E[\varepsilon_t] + \theta_1 E[\varepsilon_{t-1}] = c \quad (11)$$

La varianza es constante:

$$\begin{aligned}
\text{Var}(y_t) &= E[(\varepsilon_t + \theta_1 \varepsilon_{t-1})^2] = E[\varepsilon_t^2] + 2\theta_1 E[\varepsilon_t \varepsilon_{t-1}] + \theta_1^2 E[\varepsilon_{t-1}^2] \\
&= \sigma_\varepsilon^2 + \theta_1^2 \sigma_\varepsilon^2 = \sigma_\varepsilon^2 (1 + \theta_1^2) \quad (12)
\end{aligned}$$

cuando $k = 1$ la covarianza está definida:

$$\begin{aligned}
\text{cov}(y_t, y_{t-1}) &= E[(y_t - E(y_t))(y_{t-1} - E(y_{t-1}))] = E[(\varepsilon_t - \theta_1 \varepsilon_{t-1})(\varepsilon_{t-1} - \theta_1 \varepsilon_{t-2})] \\
&= E(\varepsilon_t \varepsilon_{t-1} - \theta_1 \varepsilon_t \varepsilon_{t-2} - \theta_1 \varepsilon_{t-1}^2 + \theta_1^2 \varepsilon_{t-1} \varepsilon_{t-2}) = E(-\theta_1 \varepsilon_{t-1}^2) = -\theta_1 \sigma_\varepsilon^2 \quad (13.1)
\end{aligned}$$

Cuando $k > 1$ las covarianzas se hacen cero, porque todo depende del término de error que se distribuye como un ruido blanco con media cero y varianza constante. La función de auto-covarianzas para un MA(1) adopta la siguiente forma:

$$\gamma_k = \begin{cases} \gamma_0 = (1 + \theta^2) \sigma_\varepsilon^2, & k = 0 \\ \gamma_1 = -\theta \sigma_\varepsilon^2, & k = 1 \\ \gamma_k = 0, & k > 1 \end{cases} \quad (13.2)$$

El vector $\mathbf{Y}_t$ se distribuye como una normal de media constante y matriz de varianzas y covarianzas:

$$\begin{pmatrix} y_t \\ \vdots \\ y_T \end{pmatrix} \sim \mathcal{N}_T \left[\begin{pmatrix} c \\ \vdots \\ c \end{pmatrix}; \begin{pmatrix} (1 + \theta_1^2)\sigma_\varepsilon^2 & \theta_1\sigma_\varepsilon^2 & 0 & \cdots & 0 \\ \theta_1\sigma_\varepsilon^2 & \ddots & \ddots & \ddots & \vdots \\ 0 & \ddots & \ddots & \ddots & 0 \\ \vdots & \ddots & \ddots & \ddots & \theta_1\sigma_\varepsilon^2 \\ 0 & \cdots & 0 & \theta_1\sigma_\varepsilon^2 & (1 + \theta_1^2)\sigma_\varepsilon^2 \end{pmatrix} \right] \quad (14)$$

Para el caso concreto de un MA(2), la esperanza incondicional también es constante:

$$E[y_t] = E[\varepsilon_t + \theta_1\varepsilon_{t-1} + \theta_2\varepsilon_{t-2}] = E[\varepsilon_t] + \theta_1 E[\varepsilon_{t-1}] + \theta_2 E[\varepsilon_{t-2}] = 0 \quad (15)$$

La varianza incondicional es constante, como ya se demostró:

$$\begin{aligned} \text{Var}(y_t) &= E[(\varepsilon_t + \theta_1\varepsilon_{t-1} + \theta_2\varepsilon_{t-2})^2] = E[\varepsilon_t^2] + \theta_1^2 E[\varepsilon_{t-1}^2] + \theta_2^2 E[\varepsilon_{t-2}^2] \\ &\quad + 2\theta_1 E[\varepsilon_t\varepsilon_{t-1}] + 2\theta_2 E[\varepsilon_t\varepsilon_{t-2}] + 2\theta_1\theta_2 E[\varepsilon_{t-1}\varepsilon_{t-2}] \\ &= \sigma_\varepsilon^2 + \theta_1^2\sigma_\varepsilon^2 + \theta_2^2\sigma_\varepsilon^2 = \sigma_\varepsilon^2(1 + \theta_1^2 + \theta_2^2) \end{aligned} \quad (16)$$

Ahora veremos las covarianzas entre los distintos instantes de tiempo. Cuando $k = 1$ la covarianza está definida como:

$$\begin{aligned} \text{cov}(y_t, y_{t-1}) &= E[(y_t - E(y_t))(y_{t-1} - E(y_{t-1}))] \\ &= E[(\varepsilon_t + \theta_1\varepsilon_{t-1} + \theta_2\varepsilon_{t-2})(\varepsilon_{t-1} + \theta_1\varepsilon_{t-2} + \theta_2\varepsilon_{t-3})] \\ &= \theta_1\sigma_\varepsilon^2 + \theta_1\theta_2\sigma_\varepsilon^2 = \sigma_\varepsilon^2(\theta_1 + \theta_1\theta_2) \end{aligned} \quad (17.1)$$

Cuando $k = 2$ la covarianza está definida como:

$$\begin{aligned} \text{cov}(y_t, y_{t-2}) &= E[(y_t - E(y_t))(y_{t-2} - E(y_{t-2}))] \\ &= E[(\varepsilon_t + \theta_1\varepsilon_{t-1} + \theta_2\varepsilon_{t-2})(\varepsilon_{t-2} + \theta_1\varepsilon_{t-3} + \theta_2\varepsilon_{t-4})] = \theta_2\sigma_\varepsilon^2 \end{aligned} \quad (17.2)$$

Para $k > 2$ se hace cero. La función de auto-covarianzas de un MA(2) adopta la siguiente forma:

$$\gamma_k = \begin{cases} \gamma_0 = (1 + \theta_1^2 + \theta_2^2)\sigma_\varepsilon^2, & k = 0 \\ \gamma_1 = (\theta_1 + \theta_1\theta_2)\sigma_\varepsilon^2, & k = 1 \\ \gamma_2 = \theta_2\sigma_\varepsilon^2, & k = 2 \\ \gamma_k = 0, & k > 2 \end{cases} \quad (17.3)$$

En todas las covarianzas hemos visto que cada una de ellas tiene en cuenta las varianzas. Finalmente, el vector $\mathbf{Y}_t$ se distribuye como una normal multivariante de media constante y matriz de varianzas y covarianzas:

$$\begin{pmatrix} y_t \\ \vdots \\ y_T \end{pmatrix} \sim \mathcal{N}_T \left[\begin{pmatrix} c \\ \vdots \\ c \end{pmatrix}; \begin{pmatrix} (1 + \theta_1^2 + \theta_2^2)\sigma_\varepsilon^2 & (\theta_1 + \theta_1\theta_2)\sigma_\varepsilon^2 & \theta_2\sigma_\varepsilon^2 & 0 & \cdots & 0 \\ (\theta_1 + \theta_1\theta_2)\sigma_\varepsilon^2 & \ddots & \ddots & \ddots & \ddots & \vdots \\ \theta_2\sigma_\varepsilon^2 & \ddots & \ddots & \ddots & \ddots & 0 \\ 0 & \ddots & \ddots & \ddots & \ddots & \theta_2\sigma_\varepsilon^2 \\ \vdots & \ddots & \ddots & \ddots & \ddots & (\theta_1 + \theta_1\theta_2)\sigma_\varepsilon^2 \\ 0 & \cdots & 0 & \theta_2\sigma_\varepsilon^2 & (\theta_1 + \theta_1\theta_2)\sigma_\varepsilon^2 & (1 + \theta_1^2)\sigma_\varepsilon^2 \end{pmatrix} \right] \quad (18)$$

A medida que imponemos un orden más alto al proceso de media móvil, asumimos un mayor grado de dependencia entre y_t y las innovaciones pasadas $\varepsilon_{t-1}, \varepsilon_{t-2}, \dots, \varepsilon_{t-q}$, introduciendo más estructura temporal. Por tanto, para identificar el orden tenemos que poder identificar el grado de dependencia entre los diferentes instantes, y lo hacemos mediante una función de covarianza poblacional de y_t con respecto a y_{t-k} —donde $k = 1, 2, \dots, k-$.

Sin embargo, esto resulta confuso porque la covarianza depende de la escala, es decir, de las unidades en que se miden los datos. Un valor de covarianza grande no tiene por qué indicar una dependencia fuerte: podría reflejar que la varianza de la serie es muy alta. Este es un caso típico en la cotización de divisas en el mercado FX. Por esta razón utilizamos el correlograma o función de auto-correlaciones simple (ACF, por sus siglas en inglés), que se obtiene mediante su estandarización por la varianza de y_t :

$$\rho(k) = \text{Corr}(y_t, y_{t-k}) = \frac{\gamma(k)}{\gamma(0)} = \frac{\text{Cov}(y_t, y_{t-k})}{\text{Var}(y_t)} \quad (19)$$

Al hacerlo, obtenemos un coeficiente adimensional que siempre se mueve en un rango de -1 a 1 . En el fondo, cuando recurrimos a la ACF lo que estamos haciendo es inferir su forma poblacional para identificar qué modelo teórico $\text{MA}(q)$ se adecúa mejor al conjunto de datos muestrales, $\hat{\rho}_k$. En este sentido, queremos saber si la correlación del instante k es realmente significativa o si, por el contrario, es un ruido blanco:

$$\begin{aligned} H_0 : \rho_k &= 0 \\ H_1 : \rho_k &\neq 0 \end{aligned} \quad (19)$$

Para este contraste individual (19) establecemos un rango de confianza, lo habitual con la normal como referencia, con un grado de confianza del 95 %, y asumiendo que la serie es ruido blanco, lo que implica que las autocorrelaciones poblacionales son nulas:

$$\hat{\rho}_k \xrightarrow{i.i.d} \mathcal{N}\left(0, \frac{1}{T}\right) \quad (20)$$

También podemos suavizar la hipótesis de ruido blanco gaussiano y no asumir normalidad del proceso subyacente, considerando que la distribución asintótica de las autocorrelaciones muestrales es aproximadamente normal, con media igual a la autocorrelación poblacional y la varianza dada por la fórmula de Bartlett (1946):

$$\hat{\rho}_k \sim \mathcal{N}(\rho_k, \text{Var}(\hat{\rho}_k)) \quad (21)$$

donde la varianza de las auto-correlaciones está relacionada con las auto-correlaciones poblacionales del proceso de la siguiente forma:

$$\text{Var}(\hat{\rho}_k) \approx \frac{1}{T} \left(1 + 2 \sum_{h=1}^{k-1} \rho_h^2 \right) \quad (22)$$

2.3. Procesos estacionarios Autorregresivos de orden p

En los procesos Autorregresivos de orden p –AR(p)– el valor actual de la serie depende directamente de sus propios valores en instantes anteriores –a diferencia del proceso MA(q)– más un término de error que se distribuye como un Ruido Blanco:

$$y_t = c + y_t + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \varepsilon_t, \quad \text{donde } \varepsilon_t \sim RB(0, \sigma_\varepsilon^2) \quad (23)$$

Imaginemos el estado anímico actual de la misma persona que en el MA(q). A diferencia del MA(q), el estado de ánimo de la persona no se reinicia cada mañana con *shocks* emocionales aleatorios, y con memoria de algún resquicio de *shocks* emocionales pasados, porque depende directamente del estado en el que se encontraba en instantes anteriores. Ahora sí que el estado emocional del pasado reciente genera una inercia emocional que se proyecta en el presente. A diferencia de la persona del ejemplo MA(q), cuyo humor se reseteaba diariamente de forma aleatoria y que guardaba regazos de *shocks* pasados muy recientes, ahora analizamos el estado anímico de alguien que es consciente de que es consciente de que su estado anímico en días previos tiene impacto en su estado anímico presente. El término más importante es y_{t-1} , que es el estado anímico del día anterior. Tras un día positivo o negativo, el ánimo no vuelve de inmediato a la normalidad como en el MA(q). Ahora, el bienestar o malestar de un día se convierte en la base sobre la que se asienta el siguiente. En este sentido, el coeficiente ϕ_1 refleja la persistencia del *shock* emocional más reciente. Además, también cuentan los estados más lejanos en el tiempo, $y_{t-2}, y_{t-3}, \dots, y_{t-p}$, aunque su influencia va disminuyendo poco a poco. La memoria emocional es más fuerte cuanto más cercano está el recuerdo en el tiempo, y se va debilitando a medida que nos alejamos con los sucesivos retardos. A pesar de todo, el *shock* aleatorio diario, ε_t , sigue presente. Son las sorpresas cotidianas como recibir buenas noticias o sufrir un contratiempo inesperado. Sin embargo, ya no actúan de manera aislada, sino que se superponen a un estado de ánimo preexistente y lo amplifican en una u otra dirección.

Para que podamos estimar los parámetros de un AR(p) impondremos estacionariedad en sentido débil y comprobaremos que se cumple (2), (3) y (4). La esperanza incondicional de un AR de orden indeterminado p se expresa de la siguiente manera:

$$\begin{aligned} E[y_t] &= E[c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-k}] \\ &= E[c] + \phi_1 E[y_{t-1}] + \phi_2 E[y_{t-2}] + \cdots + \phi_p E[y_{t-k}] + E[\varepsilon_t] = c + \sum_{i=1}^p \phi_i E[y_{t-i}] \end{aligned} \quad (24.1)$$

De manera que, despejando la esperanza de y_t , obtenemos:

$$E[y_t] = \frac{c}{1 - \sum_{i=1}^p \phi_i} \quad (24.2)$$

Esta esperanza presenta una serie de problemas. Pongamos el ejemplo más sencillo. Para un AR (1) obtendríamos únicamente el coeficiente ϕ_1 . De esta manera, si $\phi_1 = 1$ ocurre que la expresión de (24.2) adopta un valor infinito (no tendríamos una media constante finita)

por la tanto tendríamos un Paseo Aleatorio⁵ (*Random Walk*, en ingles). Si ϕ_1 va aumentando hasta la unidad tendremos una esperanza de mayor magnitud. Para cumplir con el supuesto de estacionariedad en sentido débil tenemos que imponer que $|\phi_1| < 1$ porque si no el proceso estocástico aunque definido no puede ser estacionario porque no cumple (2).

A partir de AR(1), los procesos AR(p) no basta con que $|\phi_1| < 1$ sino que para que se cumpla la condición (2) de estacionariedad en sentido débil debemos confirmar que todas las raíces del polinomio característico estén fuera del círculo unidad, $1 - \phi_1 z - \phi_2 z^2 - \dots - \phi_p z^p = 0$, es decir que todas las raíces z_j cumplan que $|z_j| > 1$ (z es una variable compleja que nos sirve a modo de representante del polinomio y sus raíces). El polinomio característico que obtengamos de un proceso puramente autorregresivo puede tener raíces con una determinada multiplicidad en función del orden con el que lo identifiquemos.

Por ejemplo, en un AR(2) lo expresamos como un polinomio de segundo grado, que en total tiene dos raíces (contadas con multiplicidad⁶). Sin embargo, esto no implica que haya siempre raíz real doble. Puede haber raíces reales y complejas. En caso de raíces reales pueden ser distintas o una doble. En caso de raíces complejas puede haber un par de forma conjugada. En series temporales es normal encontrar raíces reales (que pueden ser positivas o negativas) pero también raíces complejas. En este último caso sabemos por el Teorema Fundamental del Álgebra que el polinomio característico de un AR(p) tiene exactamente p raíces en el plano complejo (contando multiplicidades). Como los coeficientes ϕ_i son reales, si aparecen raíces complejas lo harán en pares conjugados.

Siguiendo con el ejemplo del AR(2) podemos comprobar su estacionariedad. Imaginémonos que del polinomio característico obtenemos las raíces z_1 y z_2 . El proceso es estacionario si y solo si ambas satisfacen $|z_1| > 1$ y $|z_2| > 1$ (es decir, están fuera del círculo unidad). Es común encontrar expresada esta misma idea (sobre todo en software estadísticos como Gretl o Eviews) factorizada en términos de las raíces inversas, es decir, tomando como parámetros las inversas de esas raíces. En esa forma, la condición equivalente es que los módulos de esas inversas sean menores que 1. De manera que si las dos raíces cumplen la condición de módulo, ya sea en la forma directa o en la forma con inversas, podemos confirmar que el AR(2) es estacionario.

Para representar la varianza en su forma general primero la expresamos con un AR(1), luego con un AR(2), luego con un AR(3) y por último derivamos la forma para el AR(p). La varianza incondicional de un AR(1) es:

$$\begin{aligned} \text{Var}[y_t] &= E[y_t]^2 = E[c + \phi_1 y_{t-1} + \varepsilon_t]^2 = E[\phi_1^2 y_{t-1}^2 + \varepsilon_t^2 + 2\phi_1 y_{t-1} \varepsilon_t] \\ &= \phi_1^2 E[y_{t-1}^2] + E[\varepsilon_t^2] + 2\phi_1 E[y_{t-1} \varepsilon_t] = \phi_1^2 \text{Var}[y_t] + \sigma_\varepsilon^2 \end{aligned} \quad (25.1)$$

Despejando la varianza de y_t obtenemos que la varianza incondicional de un AR(1) es:

$$\text{Var}[y_t] = \frac{\sigma_\varepsilon^2}{1 - \phi_1^2} \quad (25.2)$$

En (25.2) es importante señalar que, para asegurar estacionariedad en sentido débil, es obligatorio que $-1 < \phi_1 < 1$. En el caso de que $\phi_1 = 1$ la varianza es infinita, lo que, unido a la esperanza en (24.2), nos indicaría que ni cumple (2) ni (3). Cuando $|\phi_1| > 1$ la varianza sería

⁵El desarrollo formal del contraste de raíz unitaria de Dickey-Fuller (en su versión simple y aumentada, ADF) se recoge en el Apéndice A.

⁶La multiplicidad indica cuántas veces se repite una misma raíz.

negativa, lo cual es imposible. Además, asumiremos sin pérdida de generalidad que el proceso es estacionario y centrado en la media, asumiendo que $c = 0$.

Para la varianza incondicional de un AR(2) utilizamos las ecuaciones de Yule-Walker. Centralizamos en torno a la media con $z_t = y_t - E[y_t]$ y trabajaremos con las $\gamma(k)$ de z_t :

$$\begin{aligned} \text{Var}[z_t] = E[z_t]^2 &= E[\phi_1 z_{t-1} + \phi_2 z_{t-2} + \varepsilon_t]^2 = \phi_1^2 E[z_{t-1}^2] + \phi_2^2 E[z_{t-2}^2] \\ &+ 2\phi_1\phi_2 E[z_{t-1}z_{t-2}] + 2\phi_1 E[z_{t-1}\varepsilon_t] + 2\phi_2 E[z_{t-2}\varepsilon_t] + E[\varepsilon_t^2] \end{aligned} \quad (26.1)$$

Reduciendo $E[z_{t-1}^2] = \text{Var}(z_{t-1})$ y $E[z_{t-2}^2] = \text{Var}(z_{t-2})$ a $\gamma(0)$, y $E[z_{t-1}z_{t-2}]$ a $\gamma(1)$, la expresión (26.1) queda como (26.2):

$$\gamma(0) = \phi_1^2 \gamma(0) + \phi_2^2 \gamma(0) + 2\phi_1\phi_2 \gamma(1) + \sigma_\varepsilon^2 \quad (26.2)$$

De la misma forma, para hallar la varianza incondicional de un AR(3), tras centralizar y suponer estacionariedad:

$$\gamma(0) = (\phi_1^2 + \phi_2^2 + \phi_3^2) \gamma(0) + 2(\phi_1\phi_2 + \phi_2\phi_3) \gamma(1) + 2\phi_1\phi_3 \gamma(2) + \sigma_\varepsilon^2 \quad (27)$$

Tanto para el AR(2) como para el AR(3) la varianza depende de $\gamma(0)$ pero, adicionalmente, de $\gamma(1)$ para el AR(2), y de $\gamma(1)$ y $\gamma(2)$ para el AR(3). En el caso del AR(2), la covarianza de z_t entre t y $t-1$ tras imponer estacionariedad es:

$$\gamma(1) = \frac{\phi_1}{1 - \phi_2} \gamma(0) \quad (28)$$

Introducimos (28) en (27) y despejamos $\gamma(0)$:

$$\gamma(0) = \frac{\sigma_\varepsilon^2}{1 - (\phi_1^2 + \phi_2^2) - \frac{2\phi_1^2\phi_2}{1 - \phi_2}} \quad (29)$$

En el caso de (29), para que se cumpla estacionariedad debemos imponer simultáneamente que $-1 < \phi_2 < 1$, $\phi_1 + \phi_2 < 1$ y $\phi_2 - \phi_1 < 1$. En el caso del AR(3), las covarianzas entre t y $t-1$ y entre t y $t-2$ son:

$$\gamma(1) = \frac{\phi_1 + \phi_2\phi_3}{1 - \phi_2 - \phi_1\phi_3 - \phi_3^2} \gamma(0) \quad (30.1)$$

$$\gamma(2) = \left[\phi_2 + \frac{(\phi_1 + \phi_3)(\phi_1 + \phi_2\phi_3)}{1 - \phi_2 - \phi_1\phi_3 - \phi_3^2} \right] \gamma(0) \quad (30.2)$$

Sustituyendo (30.1) y (30.2) en (27) y despejando $\gamma(0)$:

$$\gamma(0) = \frac{\sigma_\varepsilon^2}{1 - (\phi_1^2 + \phi_2^2 + \phi_3^2) - \frac{2(\phi_1\phi_2 + \phi_2\phi_3)(\phi_1 + \phi_2\phi_3) + 2\phi_1\phi_3(\phi_1^2 + \phi_1\phi_3 + \phi_2 - \phi_2^2)}{1 - \phi_2 - \phi_1\phi_3 - \phi_3^2}} \quad (31)$$

En el caso de (31), a diferencia de (29), es más difícil establecer las condiciones simultáneas debido a la gran cantidad de coeficientes. Por eso es mejor cerciorarnos de que las raíces del polinomio característico estén fuera del círculo unidad. A partir de las ecuaciones de Yule-Walker (26.2), (29) y (31) podemos deducir la forma general de la varianza de un $AR(p)$. Usando $\gamma(h) = \rho(h)\gamma(0)$, $\gamma(0)$ queda en función solo de ϕ_i , $\rho(h)$ y σ_ε^2 :

$$\gamma(0) = \frac{\sigma_\varepsilon^2}{1 - \sum_{i=1}^p \phi_i^2 - 2 \sum_{h=1}^{p-1} \left(\sum_{i=1}^{p-h} \phi_{i+h} \phi_i \right) \rho(h)} \quad (32)$$

En cuanto a las auto-covarianzas, para cualquier p las ecuaciones de Yule-Walker dan la recursión (33.1) y (33.2). Cada auto-covarianza de orden h puede expresarse como combinación lineal de las p auto-covarianzas inmediatamente anteriores, lo que implica que $\gamma(h)$ depende solo de la distancia h y se cumple la propiedad (4):

$$\gamma(h) = \sum_{i=1}^p \phi_i \gamma(h-i) \quad (h \geq 1) \quad (33.1)$$

donde (33.2) relaciona la varianza $\gamma(0) = \text{Var}(y_t)$ con las auto-covarianzas de los primeros p retardos y la varianza del ruido. Es otra forma de expresar (32):

$$\gamma(0) = \sum_{i=1}^p \phi_i \gamma(i) + \sigma_\varepsilon^2 \quad (33.2)$$

Con (33.2) y la recursión (33.1), el conjunto $\gamma(0), \gamma(1), \dots, \gamma(p)$ queda determinado resolviendo el sistema lineal de Yule-Walker. A partir de ahí, $\gamma(h)$ para $h > p$ se obtiene iterando la recursión. Las ecuaciones de Yule-Walker son la forma de población que conecta los parámetros ϕ_i con la estructura de dependencia (autocovarianzas).

Para identificar el orden de un $AR(p)$ tenemos que generar un correlograma pero que midan la correlación de y_t e y_{t-k} cuando $y_{t-1}, \dots, y_{t-k+1}$ es constante, es decir controlando por todos los retardos intermedios. Lo que queremos por tanto es una función de autocorrelaciones parcial (PACF, por sus siglas en inglés) en contraposición a ACF que para los $MA(q)$ funciona bien dado que tiene una estructura temporal muy acotada, determinada por las innovaciones y no por la propia serie y_t . Para un retardo k , primero regresamos y_t usando únicamente los retardos intermedios $y_{t-1}, \dots, y_{t-k+1}$. El residuo de esa regresión, u_t , es la parte de y_t que no se debe a esos retardos. Después hacemos lo mismo con y_{t-k} . Lo regresamos sobre los mismos retardos intermedios $y_{t-1}, \dots, y_{t-k+1}$ y guardamos el residuo v_{t-k} , es decir, la parte de y_{t-k} cuya variabilidad no está captada por los retardos intermedios. Entonces, la PACF en k mide la correlación entre esos dos residuos, de modo que captura la relación directa entre y_t e y_{t-k} una vez eliminados la variabilidad captada por los retardos indirectos que pasan por $y_{t-1}, \dots, y_{t-k+1}$.

3. Descomposición de Wold

El Teorema de descomposición de Wold (1954) se utiliza para representar un proceso estocástico débilmente estacionario como la suma ortogonal de un componente determinista y otro no determinista. En ausencia de componentes deterministas, el proceso puede expresarse como la

suma de un término constante ($\mu = E[y_t]$) y la combinación lineal infinita de los errores que se distribuyen como un RB, con el coeficiente $\psi_0 = 1$:

$$y_t = \mu + \sum_{i=0}^{\infty} \psi_i \cdot \varepsilon_{t-i} \quad \text{donde } \varepsilon_t \sim RB \text{ y } \psi_0 = 1 \quad (34)$$

Haciendo uso de la notación B de *backshift* utilizada por Peña (2011), podemos expandir (34) como:

$$y_t = \mu + (1 + \psi_1 B + \psi_2 B^2 + \psi_3 B^3 + \dots) \varepsilon_t \quad (35)$$

Dado que no tienen componentes deterministas podemos aproximar el término estocástico al que le hemos impuesto estacionariedad débil, como un polinomio infinito que denominamos función de transferencias, $\Psi_{\infty}(B)$, y que podemos aproximar como una función racional en el sentido de Padé. Lo hacemos mediante el cociente de un polinomio de orden q partido de un polinomio de orden p ⁷:

$$\Psi_{\infty}(B) \approx (1 + \psi_1 B + \psi_2 B^2 + \dots) = \frac{\Theta(B)}{\Phi(B)} = \frac{1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q}{1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p} \quad (36)$$

Podemos establecer tres casuísticas para (36). Para el caso del MA(q), cuando $p = 0$, la expresión queda:

$$(1 + \psi_1 B + \psi_2 B^2 + \dots) \approx (1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q) \quad (37)$$

En este caso los ψ_i del proceso MA(q) son $\psi_0 = 1$, $\psi_1 = \theta_1$, $\psi_2 = \theta_2, \dots, \psi_q = \theta_q$, asumiendo $\psi_i = 0$ si $i > q$. De esta manera que si por ejemplo aproximamos un proceso estacionario con un MA(1) estamos asumiendo que $\rho_i = 0$ cuando $i > 1$. Entonces (36) podemos reescribirla como:

$$y_t = \mu + \sum_{i=0}^{\infty} \psi_i \varepsilon_{t-i} = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q} \quad (38)$$

Un MA(q) puede representarse como un AR(∞). Para el caso del AR(p), (36) con $q = 0$:

$$(1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p) y_t = \varepsilon_t \quad (39)$$

No obstante, queremos obtener la de y_t y lo conseguimos multiplicando por la inversa en ambos lados de la igualdad:

$$\begin{aligned} & (1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p)(1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p)^{-1} y_t \\ & = (1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p)^{-1} \varepsilon_t \end{aligned} \quad (40)$$

⁷Aunque aquí utilizamos una derivación algebraica basada en operadores de retardo, la demostración original de Herman Wold se formula en el marco geométrico de los espacios de Hilbert.

De esta forma la multiplicación de polinomios de la ecuación anterior es la identidad y tenemos la función de y_t como el producto de ϵ_t y la función polinómica elevado a menos uno. La inversa de un polinomio es un polinomio infinito, y el producto es igual a uno:

$$(1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p)(1 + \xi_1 B + \xi_2 B^2 + \dots) = 1 \quad (41.1)$$

A partir de aquí expresamos la representación de Wold del $AR(p)$ y obtenemos la función $\Phi(B)y_t$:

$$\Phi(B)y_t = (1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p)y_t = \epsilon_t \quad (42)$$

Hay que tener cuidados con que las raíces estén fuera del círculo unidad y para eso se debe cumplir la invertibilidad del polinomio de orden k . Tenga en cuenta el lector que al convertir la ecuación inmediatamente anterior en términos del polinomio característico hemos llegado a la conclusión de que un $AR(p)$ lo hemos podido escribir como un $MA(\infty)$ y es que a la hora de derivar las propiedades de los autorregresivos de orden p ya se llegaba a esta conclusión.

$$y_t = \Phi(B)^{-1}\epsilon_t = (1 + \xi_1 B + \xi_2 B^2 + \xi_3 B^3 + \dots)\epsilon_t \quad (43)$$

De esta manera obtenemos la representación a partir de $\Phi(B)\Phi^{-1}(B) = 1$. Al desarrollar el producto y agrupar por potencias de B se obtiene:

$$\begin{aligned} &= 1 + (\xi_1 - \phi_1)B + (\xi_2 - \phi_1\xi_1 - \phi_2)B^2 + (\xi_3 - \phi_1\xi_2 - \phi_2\xi_1 - \phi_3)B^3 + \dots \\ &+ (\xi_p - \phi_1\xi_{p-1} - \phi_2\xi_{p-2} - \dots - \phi_{p-1}\xi_1 - \phi_p)B^p + \dots \\ &+ (\xi_{p+1} - \phi_1\xi_p - \phi_2\xi_{p-1} - \dots - \phi_p\xi_1)B^{p+1} \\ &+ (\xi_{p+2} - \phi_1\xi_{p+1} - \phi_2\xi_p - \dots - \phi_p\xi_2)B^{p+2} + \dots \end{aligned} \quad (41.2)$$

Como el producto es 1, para $k \geq 1$ los coeficientes de B^k deben ser cero. Igualando coeficientes obtenemos $\xi_0 = 1$; $\xi_1 = \phi_1$; $\xi_2 = \phi_1\xi_1 + \phi_2$; $\xi_3 = \phi_1\xi_2 + \phi_2\xi_1 + \phi_3$; y en general $\xi_k = \sum_{i=1}^{\min(p,k)} \phi_i \xi_{k-i}$ para $k \geq 1$.

Ahora un $MA(q)$ y un $AR(p)$ se produce cuando tanto p como q es diferente de cero. Tengo un vector de $\mathbf{Y}_t$ que es un polinomio infinito en la forma de Wold de ϵ_t y esto lo puedo aproximar como un cociente entre dos polinomios, un polinomio de orden q en el numerador y un polinomio de orden p en el denominador. Esta aproximación recibe el nombre de $ARMA(p, q)$ que se puede ver en la ecuación (31). El cumplimiento de la invertibilidad del $MA(q)$ y de la estacionariedad del $AR(p)$ permite obtener la representación $MA(\infty)$ con el que obtenemos los coeficientes que componen la función de transferencias; $B^0 : \psi_0 = 1$; $B^1 : \psi_1 = \theta_1 + \phi_1$; $B^2 : \psi_2 = \theta_2 + \phi_1\psi_1 + \phi_2$; $B^3 : \psi_3 = \theta_3 + \phi_1\psi_2 + \phi_2\psi_1 + \phi_3$; $B^k : \psi_k = \sum_{i=1}^{\min(p,k)} \phi_i\psi_{k-i} + \theta_k$.

De esta manera obtenemos las tres casuísticas en base a (36). En el caso del $MA(q)$ cuando los $p = 0$, exigimos que las raíces de $\Theta(z) = 0$ estén fuera del círculo unidad para que cumpla la condición de invertibilidad para obtener la función de transferencias con el que recuperar la representación $AR(\infty)$. En este caso sabemos que es estacionario porque asumimos RBG con varianza finita de las innovaciones en (8). En el caso del $AR(p)$ cuando los $q = 0$, exigimos que las raíces de $\Phi(z) = 0$ estén fuera del círculo unidad para que cumpla la condición de estacionariedad cuyo cumplimiento permite que como operador sea invertible y por tanto que un $AR(p)$ lo hayamos podido representar como un $MA(\infty)$. En el caso del $ARMA(p, q)$, exigimos

ambas condiciones mencionadas anteriormente. Por un lado, que el polinomio característico del $AR(p)$ sea invertible como operador, lo que equivale a que se cumpla la condición de estacionariedad (que permite que nuestro proceso estocástico sea estable). Por otro lado, para asegurar que el modelo sea identificable y único, exigimos la condición de invertibilidad sobre el polinomio característico del $MA(q)$, es decir, que las raíces de $\Theta(z) = 0$ estén fuera del círculo unidad. Estas condiciones nos permite obtener la representación $MA(\infty)$ del $ARMA(p, q)$ ⁸

Finalmente obtenemos el $ARMA(p, q)$ reordenando (36) y asumiendo que $E[y_t] = 0$ y gaussianidad del ruido blanco:

$$y_t = \underbrace{\phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p}}_{AR(p)} + \varepsilon_t + \underbrace{\theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \cdots + \theta_q \varepsilon_{t-q}}_{MA(q)} \quad (44)$$

A la hora de comprobar el cumplimiento de (2), (3) y (4) hemos impuesto que tenemos un proceso débilmente estacionario y, por tanto, en caso de que no lo sea, podemos transformarlo.

4. Estimación

Una vez identificado el orden del proceso estocástico $ARMA(p, q)$, bajo las restricciones de estacionariedad en sentido débil e invertibilidad, tenemos que estimar sus parámetros. Los parámetros los conforman los coeficientes $AR(p)$ $-\phi_1, \phi_2, \dots, \phi_p-$, los coeficientes $MA(q)$ $-\theta_1, \theta_2, \dots, \theta_q-$, la media del proceso $-E[y_t]-$ y la varianza de los residuos $-\sigma_\varepsilon^2-$.

La forma habitual de hacerlo es mediante un algoritmo de optimización que no requiera independencia entre los valores (dada la naturaleza de una serie temporal), como es el algoritmo de estimación por máxima verosimilitud (MLE). Consiste en maximizar una función de verosimilitud que puede ser condicional o exacta. En nuestro caso podemos maximizar mediante la verosimilitud exacta, dado que hemos supuesto que el vector de residuos es un proceso de ruido blanco gaussiano.

Hasta ahora hemos hablado que para un proceso estacionario en sentido fuerte las distribuciones de densidad conjunta de probabilidad marginales es igual a la conjuntas porque no cambian cuando desplazas el tiempo. En cambio, en los procesos estacionarios en sentido débil solo exigimos que la media y las auto covarianzas sean constantes en el tiempo, lo que no garantiza que las distribuciones conjuntas sean invariantes frente a desplazamientos temporales.

Bajo el supuesto de gaussianidad, la estructura de auto-covarianzas define por completo la distribución conjunta del proceso estacionario en sentido débil. Esto nos permite factorizar la distribución de densidad conjunta a través de las condicionales mediante la descomposición del error de predicción, que expresa la verosimilitud en términos de la secuencia de errores de predicción a un paso, $e_t = (w_t - w_{t|t-1})$, y sus varianzas condicionales estandarizadas, $v_{t|t-1}$. La aplicación de la versión iterada de la identidad básica de la función de probabilidad densidad conjunta $-f(w_T)-$ nos permite escribirla como producto de la densidad de las condicionales:

⁸[Web propia](#) para generar series $ARMA/AR/MA$ a partir de su representación $MA(\infty)$, y generar la trayectoria dinámica ante un *shock* unitario en el término de innovación (ε_t). Los coeficientes de la función de transferencia constituyen la función de respuesta al impulso (IRF), que mide la derivada $\partial y_{t+k} / \partial \varepsilon_t$. Además, la aplicación simula una trayectoria muestral del proceso y estima sobre ella el modelo construido para obtener una IRF estimada y compararla con la respuesta teórica. Este ejercicio es muy habitual en modelos macroeconómicos dinámicos de equilibrio general y estocástico.

$$f(w_1, \dots, w_T) = f(w_1)f(w_2 | w_1)f(w_3 | w_2, w_1) \dots f(w_T | w_{T-1}, \dots, w_1) \quad (45)$$

Como las innovaciones (e_t) se distribuyen como un ruido blanco gaussiano con media cero y varianza constante (σ^2) , el vector $W_t = (w_1, \dots, w_T)$ es normal multivariante y todas sus marginales y condicionales son normales. La predicción óptima a un paso de w_t a partir de la información pasada $\mathcal{F}_{t-1} = \{w_{t-1}, \dots, w_1\}$ es:

$$w_{t|t-1} = E[w_t | w_{t-1}, \dots, w_1] \quad (46)$$

y constituye la mejor predicción en el sentido de minimizar el error cuadrático medio. El error de predicción a un paso es $e_t = w_t - w_{t|t-1}$, que bajo normalidad tiene media cero, y su varianza condicional es:

$$\text{Var}(w_t | w_{t-1}, \dots, w_1) = \text{Var}(e_t | \mathcal{F}_{t-1}) = \sigma^2 v_{t|t-1} \quad (47)$$

donde el escalar $v_{t|t-1}$ depende de los parámetros del ARMA(p, q) y es 1 en muchos casos, excepto en los primeros pasos, donde hay problemas de inicialización⁹. Así, cada factor del producto de densidades de las condicionales de $f(w_T)$ es una densidad normal:

$$w_t | w_{t-1}, \dots, w_1 \sim \mathcal{N}(w_{t|t-1}, \sigma^2 v_{t|t-1}) \quad (48)$$

Por tanto, la densidad es:

$$f(w_t | w_{t-1}, \dots, w_1) = \frac{1}{\sqrt{2\pi\sigma^2 v_{t|t-1}}} \exp\left(-\frac{1}{2\sigma^2 v_{t|t-1}}(w_t - w_{t|t-1})^2\right) \quad (49)$$

A partir de (49), la verosimilitud se puede obtener de manera condicional o exacta. En la condicional solo usamos $t \geq r+1$, donde $r = \max(p, q)$, fijando los primeros residuos ($v_{t|t-1} = 1$ para los valores iniciales). En la exacta usamos todos los términos $t = 1, \dots, T$ manteniendo los valores correctos de $v_{t|t-1}$. Generalizando (49) como producto de densidades condicionales obtenemos la densidad marginal conjunta exacta:

$$f(w_T) = \prod_{t=1}^T \frac{1}{\sqrt{2\pi\sigma^2 v_{t|t-1}}} \exp\left(-\frac{1}{2\sigma^2 v_{t|t-1}} e_t^2\right) \quad (50)$$

A partir de (50) obtenemos la log-verosimilitud exacta $L(\beta)$, con el vector de parámetros $\beta = (E[y_t], \phi_1, \dots, \phi_p, \theta_1, \dots, \theta_q, \sigma_e^2)$, agrupando constantes y tomando logaritmos:

$$L(\beta) = \frac{T}{2} \log(2\pi) - \frac{T}{2} \log(\sigma^2) - \frac{1}{2} \sum_{t=1}^T \log(v_{t|t-1}) - \frac{1}{2\sigma^2} \sum_{t=1}^T \frac{e_t^2}{v_{t|t-1}} \quad (51)$$

La clave es que tanto e_t como $v_{t|t-1}$ dependen de los parámetros del ARMA(p, q), por lo que la función de verosimilitud no es lineal y su maximización exige emplear métodos numéricos. Una forma habitual es utilizar una representación en espacio de estados y aplicar el filtro de Kalman para obtener, para cada valor de β , la predicción del estado, la observación, el error de

⁹Por ejemplo, para el AR(1) el escalar $v_{t|t-1} = 1$ para $t \geq 2$ salvo en $v_{1|0} = (1 - \phi^2)^{-1}$, véase (25.2).

predicción y su varianza¹⁰. Una vez descrito el procedimiento de maximización de (45), cabe preguntarse bajo qué condiciones los estimadores así obtenidos poseen buenas propiedades estadísticas.

Condiciones de regularidad de la estimación por máxima verosimilitud. Bajo las siguientes condiciones de regularidad:

- (i) el modelo $\text{ARMA}(p, q)$ debe ser estacionario en sentido débil y, por tanto, cumplir (2), (3) y (4);
- (ii) en el modelo $\text{ARMA}(p, q)$ no puede haber raíces que se cancelen, porque entonces dejaría de ser $\text{ARMA}(p, q)$ y pasaríamos a un $\text{ARMA}(p-1, q-1)$. De manera que si estimamos más parámetros de los que realmente hay, es imposible que tengamos consistencia en los estimadores obtenidos por máxima verosimilitud;

la estimación de los parámetros por máxima verosimilitud tiene buenas propiedades estadísticas para grandes muestras. De manera que los estimadores que obtengamos serán aproximadamente normales y asintóticamente insesgados y eficientes, por lo que faltaría ver la significatividad individual y conjunta de los estimadores.

5. Diagnóstico

En cuanto a la diagnosis del modelo, tenemos que comprobar que los residuos provienen de un ruido blanco poblacional. Si esto es así, podemos confirmar que para todos los residuos las medias marginales son nulas, que la varianza marginal es constante y, por tanto, independiente del instante t , y que existe ausencia de heterocedasticidad entre los retardos de los residuos. A la hora de chequear esto es mucho más acertado hacer un contraste de hipótesis individual y conjunto, porque que una autocorrelación sea cero no significa que en conjunto puedan serlo. Para evitar que valores positivos y negativos se cancelen, se elevan al cuadrado: la suma al cuadrado de esos residuos supone comparar las auto-correlaciones de los residuos de la muestra con respecto a las de la población, es decir, la distancia euclídea.

Para ello hacemos uso del estadístico Ljung-Box (1978) que, bajo la hipótesis nula de residuos de ruido blanco, sigue aproximadamente una distribución chi-cuadrado. Si el tamaño muestral fuese infinito, cada autocorrelación muestral tendría distribución aproximadamente $\mathcal{N}(0, \frac{1}{T})$ y, tras la tipificación $t_k = \frac{\hat{\rho}_k}{\sqrt{\text{Var}(\hat{\rho}_k)}}$, $t_k \sim \mathcal{N}(0, 1)$. La suma de cuadrados de estas variables tipificadas adopta una distribución chi-cuadrado:

$$\mathcal{N}(0, 1)^2 + \mathcal{N}(0, 1)^2 + \dots + \mathcal{N}(0, 1)^2 = t_1^2 + t_2^2 + \dots + t_m^2 \approx \chi_m^2 \quad (52)$$

Para tamaños muestrales finitos, acumulamos la distancia de ese vector de autocorrelaciones respecto al vector nulo mediante una suma ponderada de las autocorrelaciones estimadas al cuadrado, que conduce al estadístico de Ljung-Box:

$$Q(m) = T(T+2) \sum_{k=1}^m \frac{\widehat{\rho}_k^2}{T-k} \quad (53)$$

¹⁰Para profundizar en los aspectos técnicos de esta sección, véase Casals et al. (2016, Cap. 5) y Hamilton (1994, Cap. 13).

El estadístico resultante se distribuye aproximadamente como una $\chi^2_{m-(p+q)}$, donde el número de grados de libertad es la diferencia entre el número de retardos considerados $-m-$ y los parámetros estimados del modelo $-p+q-$. Así, si el contraste arroja evidencia para rechazar la hipótesis nula, significa que la distancia euclídea entre las autocorrelaciones muestrales y las poblacionales es grande y, por tanto, los residuos no se comportan como un ruido blanco, y viceversa. Existen otros estadísticos para realizar este mismo contraste conjunto, como el de Monti (1994). Por ello es importante combinar la información de estos contrastes con la inspección gráfica de los residuos y de los residuos al cuadrado.

6. Predicciones

Por último, nos centramos en la predicción de y_T en algún momento futuro basada en un conjunto de información $I_T = \{y_T, y_{T-1}, y_{T-2}, \dots\}$. Si tenemos este conjunto, tenemos obligatoriamente los residuos $\hat{\varepsilon}_T, \hat{\varepsilon}_{T-1}, \hat{\varepsilon}_{T-2}, \dots$. Por tanto, podemos predecir el valor puntual del próximo valor e indicar el grado de confianza mediante un intervalo de predicción. Para obtener la mejor predicción posible, la forma más eficiente es minimizar el error cuadrático medio (MSE), dado que penaliza de forma equivalente los valores positivos y negativos y su tratabilidad en el problema de optimización es mejor.

Con esta información obtenemos la predicción puntual de orden T , que es el valor esperado de y_{T+l} condicionado a la información hasta T :

$$\hat{y}_T(l) = E[y_{T+l} | I_T] = E[y_{T+l} | y_T, y_{T-1}, \dots, \varepsilon_T, \varepsilon_{T-1}, \dots] \quad (54)$$

además de la predicción de los errores a horizonte l , asumiendo que las innovaciones se distribuyen como un ruido blanco gaussiano:

$$e_T(l) = Y_{T+l} - \hat{y}_T(l) \sim \mathcal{N}(0, \text{Var}[e_T(l)]) \quad (55)$$

En realidad lo que estamos haciendo es minimizar el error esperado al cuadrado con el objetivo de encontrar el mínimo $e_T(l)$:

$$\min_g E[(Y_{T+l} - \hat{y}_T(l))^2] \quad (56)$$

Obtenemos el intervalo de confianza asumiendo que las innovaciones se distribuyen como una normal:

$$y_{T+l} \in \left(\hat{y}_T(l) \pm z_{\frac{\alpha}{2}} \sqrt{\text{Var}[e_T(l) | I_T]} \right) \quad (57)$$

donde la varianza del error de predicción a horizonte l condicionada a la información hasta T se representa como polinomio infinito de la parte MA, dado que cumple las hipótesis de estacionariedad en sentido débil (2), (3) y (4):

$$\text{Var}[e_T(l) | I_T] = \sigma^2 \sum_{j=0}^{h-1} \psi_j^2 \quad (58)$$

Si se cumplen las condiciones de invertibilidad y estacionariedad del proceso ARMA(p, q), AR(p) y/o MA(q), los coeficientes ψ_i de (58) serán, para el caso de un ARMA(p, q):

$$V[e_T(h) | I_T] = \sigma^2 \sum_{j=0}^{h-1} \underbrace{\left(\underbrace{1}_{\psi_0^2} + \underbrace{(\theta_1 + \phi_1)^2}_{\psi_1^2} + \underbrace{(\theta_2 + \phi_1\theta_1 + \phi_1^2 + \phi_2)^2}_{\psi_2^2} + \dots \right)}_{\psi_j^2} \quad (59.1)$$

para un AR(p):

$$V[e_T(h) | I_T] = \sigma^2 \sum_{j=0}^{h-1} \underbrace{\left(\underbrace{1}_{\psi_0^2} + \underbrace{\phi_1^2}_{\psi_1^2} + \underbrace{(\xi_1\phi_1 + \phi_2)^2}_{\psi_2^2} \right)}_{\psi_j^2} \quad (59.2)$$

y para un MA(q):

$$V[e_T(h) | I_T] = \sigma^2 \sum_{j=0}^{h-1} \underbrace{\left(\underbrace{1}_{\psi_0^2} + \underbrace{(\theta_1)^2}_{\psi_1^2} + \underbrace{(\theta_2)^2}_{\psi_2^2} + \dots \right)}_{\psi_j^2} \quad (59.3)$$

7. Aplicación práctica con datos reales

Por último, quedaría aplicar esta metodología sobre series de datos temporales reales¹¹, previa una explicación contextual de por qué presenta su respectiva evolución. Primero utilizamos la serie de ocupados y, en segundo lugar, la serie de parados, para en último lugar terminar prediciendo la tasa de paro mediante la predicción de las dos anteriores (c) y compararla con su predicción si la hubiéramos predicho por sí sola (nc). Se utilizará el modelo ARMA(p, q) multiplicativo, imponiendo estacionariedad mediante una diferenciación regular y otra estacional, e introduciendo variables exógenas en determinados instantes para reducir la varianza de las observaciones. Con estas restricciones obtenemos el modelo SARIMAX(p, d, q) $\times$ (P, D, Q, S).

7.1. Contexto

La evolución del empleo en España muestra un crecimiento ininterrumpido desde 2002 hasta el estallido de la crisis financiera y económica de 2008, momento en el que el país alcanzó una cifra récord de casi 21 millones de personas ocupadas. Sin embargo, tras la crisis, el número de trabajadores descendió bruscamente hasta tocar su nivel más bajo en 2014, con apenas 17 millones de ocupados y más de 6 millones de parados.

¹¹Se ha seleccionado RStudio como entorno de desarrollo de código debido a que es un software de código abierto y licencia gratuita que proporciona paquetes especializados de análisis de series temporales, entre los que se encuentra la librería `forecast`. RStudio también incorpora el ecosistema `tidymodels` –equivalente a Scikit-learn en Python– que permite implementar modelos de aprendizaje estadístico con vocación estrictamente predictiva.




Gráfico 7.1: Evolución trimestral de Parados, Ocupados y Tasa de Paro en España (2002–2023).

Fuente: Instituto Nacional de Estadística (INE). Nota: la tasa de paro se ha construido a partir de la serie de parados y ocupados como $\frac{\text{Parados}}{\text{Parados} + \text{Ocupados}}$.

Para revertir esta situación, la reforma laboral de 2012 introdujo cambios significativos en tres áreas clave: la regulación del despido (i), las prestaciones por desempleo (ii) y la estructura de la negociación colectiva (iii).

- (i) En lo referente a la regulación del despido, la reforma abarató y facilitó las extinciones de contrato. Por un lado, se simplificó el despido por causas objetivas (como una situación económica negativa de la empresa), estableciendo una indemnización de 20 días por año trabajado si la compañía demostraba una reducción de ingresos durante tres trimestres consecutivos. Por otro lado, se redujo el coste del despido improcedente de 45 a 33 días por año trabajado. Además, se eliminó la necesidad de autorización administrativa para los Expedientes de Regulación de Empleo (ERE), permitiendo al empresario ejecutar su decisión si, tras un mes de negociación, no se alcanzaba un acuerdo.
- (ii) En cuanto a las prestaciones por desempleo, la reforma de 2012 las redujo para los nuevos parados a partir del sexto mes, disminuyendo la cuantía del 60 % al 50 % de la base reguladora.
- (iii) Respecto a la estructura de la negociación colectiva, se produjeron dos cambios fundamentales. El más drástico afectó a la llamada ultraactividad de los convenios. Antes de la reforma, este principio garantizaba que, cuando un convenio colectivo caducaba, sus condiciones (salarios, horarios, etc.) se mantenían vigentes de forma indefinida hasta que se firmara uno nuevo. La reforma de 2012 acabó con esta prórroga automática, limitándola a un máximo de un año. A partir de ese momento, si en ese plazo no se alcanzaba un nuevo acuerdo, el convenio antiguo perdía su validez, y los trabajadores pasaban a regirse por el convenio de ámbito superior o, en su defecto, por las condiciones mínimas del Estatuto de los Trabajadores. El segundo gran cambio fue dar prioridad aplicativa a los convenios de empresa sobre los convenios sectoriales, lo que permitió a cada compañía adaptar las condiciones laborales a su situación particular con mayor facilidad.

Las reformas anteriores (1997, 2001, 2006, 2010) tenían como uno de sus principales objetivos generar mayor estabilidad laboral, dado que uno de los problemas estructurales de la economía española desde la transición es el exceso de empleo temporal, que desincentiva la inversión en capital humano y limita la productividad. Las dos últimas reformas consiguieron reducir la temporalidad, pero en gran medida a costa de destruir empleo temporal existente, no de convertirlo en indefinido (Myro y Delgado, 2019). A partir de 2014 todas las series muestran una mejoría producida por el crecimiento económico posterior, solo interrumpida de forma relativamente moderada por la crisis generada por la pandemia del coronavirus en el primer trimestre de 2020.

7.2. Serie temporal de ocupados

En lo relativo al nivel de ocupados, el objetivo principal consiste en predecir la evolución para los cuatro trimestres del año 2024. Tras el análisis previo, el modelo seleccionado es un $\text{SARIMAX}(1,1,0) \times (2,1,1,4)$, al cual se han incorporado variables exógenas detectadas automáticamente mediante la librería `forecast`. En una primera aproximación visual, la serie presenta estacionariedad condicionada por una tendencia dividida en etapas claras (2002–2008, 2009–2014, 2015–2020 y 2021–2023) y una evidente estacionalidad, tal como se aprecia en el gráfico 7.2.1.




Gráfico 7.2.1: Descomposición de la serie de ocupados original, y_t .

Dada la magnitud de los valores, se procedió a estabilizar la varianza aplicando logaritmos $\log(y_t)$, seguidos de una diferencia regular para corregir la tendencia, $\Delta \log(y_t) = \log(y_t) - \log(y_{t-1})$, y estacional, $\Delta_4 \log(y_t) = \log(y_t) - \log(y_{t-4})$, para corregir el ciclo anual, como se ve en el gráfico 7.2.2.




Gráfico 7.2.2: Descomposición de la serie ocupados transformada, $(1 - B)(1 - B^4) \log(y_t)$.

Sin embargo, al verificar las propiedades de la serie transformada mediante el test de Dickey-Fuller Aumentado (ADF), se encontró evidencia de no estacionariedad, dado que no fue posible rechazar la hipótesis nula al 99 % de confianza (estadístico ADF de $-3,310$ con un p -valor de $0,0144$). Esto obligó a realizar un análisis de intervención mediante la inclusión de variables *dummy*. La primera intervención corresponde al impacto de la pandemia del COVID-19, identificada como un cambio temporal (*Time Change* o TC) con fecha de inicio en el segundo trimestre de 2020 ($T_0 = 2020Q2$) y un factor de decaimiento $\delta \approx 0,7$. Al trabajar con dobles diferencias, este regresor se introduce como $x_T = \Delta \Delta_4 TC_t(T_0, \delta) = (1 - B)(1 - B^4) TC_t(T_0, \delta)$, donde $TC_t(T_0, \delta) = 0$ si $t < T_0$ y δ^{t-T_0} si $t \geq T_0$. El signo negativo del coeficiente estimado confirma que este *shock* transitorio provocó un desplome inmediato que se corrigió progresivamente. Asimismo, se modelizó la crisis económica de 2008 como un cambio de nivel (*Level Shift*) con fecha $T_0 = 2009Q1$, que bajo la doble diferencia toma valor 1 en 2009Q1, -1 en 2010Q1 y 0 en el resto.

Tras la incorporación de estas exógenas, el nuevo test ADF confirmó que el proceso es estacionario en sentido débil con un nivel de confianza superior al 99 % (estadístico de $-3,272$ y p -valor de $0,016$), como se comprueba en el gráfico 7.2.3.




Gráfico 7.2.3: Gráfico de residuos estandarizados con *dummies* y sin *dummies*.

Con la serie estacionaria, el análisis de los correlogramas simple y parcial (ACF y PACF) permitió identificar la estructura del modelo como $SARIMAX(1,1,0) \times (2,1,1)_4$.




Gráfico 7.2.4: Funciones de auto correlación simple (ACF) y parcial (PACF) de $(1 - B)(1 - B^4) \log(y_t)$.

Las estimaciones de los coeficientes, presentadas en la tabla 7.2.5, resultaron estadísticamente significativas.

	AR1	SAR1	SAR2	SMA1	LS_2009Q1	TC_2020Q2
Coefficiente	0,7530	-0,1190	-0,3954	-0,3738	-0,0167	-0,0710
(s.e.)	(0,0803)	(0,1837)	(0,1247)	(0,2014)	(0,0035)	(0,0030)

Tabla 7.2.5: Estimaciones de los coeficientes del modelo identificado $SARIMAX(1,1,0) \times (2,1,1,4)$.

Los criterios de información (AIC, BIC) recogidos en la tabla 7.2.6 validan la bondad del ajuste.

Sigma ²	log likelihood	AIC	AICc	BIC
$2,822 \times 10^{-5}$	319,23	-624,47	-622,98	-607,54

Tabla 7.2.6: Estadísticos del modelo identificado SARIMAX(1,1,0)x(2,1,1,4).

En cuanto a la capacidad predictiva dentro de la muestra, las métricas de error detalladas en la tabla 7.2.7 indican una alta precisión en el ajuste histórico.

MASE	ACF1	ME	RMSE	MAE	MPE	MAPE
-0,0001173515	0,004968788	0,003833235	-0,003279871	0,1301509	0,1184753	-0,06520178

Tabla 7.2.7: Medidas de ajuste de la muestra de entrenamiento.

La validación final del modelo se sustentó en el análisis de los residuos. Como muestra el gráfico 7.2.8 y los contrastes de Ljung-Box (tabla 7.2.9), no existe autocorrelación significativa simple ni al cuadrado. Adicionalmente, el test de Jarque-Bera y el gráfico Q-Q *plot* confirman que los residuos siguen una distribución normal, permitiendo concluir que se comportan como un ruido blanco gaussiano.




Gráfico 7.2.8: Cuadro resumen de diagnóstico de los residuos del modelo 7.2.5. Nota: la primera fila muestra la ACF y PACF de los residuos; la segunda, la de los residuos al cuadrado; la tercera, el QQ-plot y el gráfico de densidad de los residuos frente a la normal, incluyendo el test semiparamétrico de Jarque-Bera como leyenda.

Lag	Residuos		Resid. al cuad.		Lag	Residuos		Resid. al cuad.	
	Q	p	Q	p		Q	p	Q	p
1	0.36350	—	0.20362	0.65182	19	9.32890	0.80942	18.66821	0.47830
2	0.97191	—	0.37065	0.83084	20	9.50405	0.84972	19.03290	0.51969
3	1.04174	—	0.65878	0.88285	21	9.51668	0.89062	19.47224	0.54897
4	1.08601	0.00000	0.77942	0.94119	22	10.80048	0.86675	21.72183	0.47659
5	1.11535	0.29092	2.22772	0.81682	23	12.57723	0.81605	21.97274	0.52796
6	2.07378	0.35456	2.97254	0.81229	24	12.94102	0.84158	21.86274	0.58170
7	2.53846	0.46838	3.46625	0.83879	25	13.23779	0.86695	22.78751	0.58997
8	2.60343	0.62622	4.08044	0.84970	26	13.24094	0.89995	23.49705	0.60470
9	2.60882	0.76003	4.18429	0.89887	27	14.23254	0.89302	23.56071	0.65456
10	2.87543	0.82431	4.20952	0.93740	28	15.22995	0.88620	24.06208	0.67825
11	4.66600	0.70065	9.62396	0.56450	29	15.88214	0.89228	25.75343	0.63864
12	4.66668	0.79253	12.33183	0.41941	30	15.88378	0.91825	26.26754	0.66141
13	5.02902	0.83177	13.53540	0.40736	31	15.91785	0.93816	26.92769	0.67580
14	5.05525	0.87470	13.71407	0.47122	32	16.19719	0.94908	28.92005	0.62322
15	5.05525	0.88746	13.78372	0.54199	33	16.38802	0.95972	29.29501	0.65224
16	7.41814	0.76428	15.99585	0.45329	34	18.67154	0.92942	30.90108	0.62040
17	7.49768	0.82305	17.15093	0.44419	35	21.03980	0.88664	36.73372	0.38845
18	9.27820	0.75162	17.65491	0.47859	36	21.45591	0.92119	37.19329	0.41389

Tabla 7.2.9: Contraste conjunto de Ljung–Box para residuos y residuos al cuadrado (modelo 7.2.5).

Finalmente, las proyecciones realizadas para 2024 indican una tendencia creciente en el nivel de ocupación. Tal como se detalla en la tabla 7.2.11, se estima que la ocupación alcanzará aproximadamente 21,481 miles de personas en el primer trimestre, ascendiendo progresivamente hasta los 22.331 miles en el cuarto trimestre. Conforme avanza el horizonte temporal, los intervalos de confianza al 95 % se ensanchan, reflejando el aumento natural de la incertidumbre (gráfico 7.1.9).




Gráfico 7.1.9: Gráfico de predicción de la serie en logaritmos.

Periodo	Predicción (log)	Intervalo de confianza (95 %)
2024Q1	3,067170	[3,056759; 3,077581]
2024Q2	3,091735	[3,070724; 3,112746]
2024Q3	3,104179	[3,072166; 3,136192]
2024Q4	3,105980	[3,063053; 3,148906]
Periodo	Predicción real [IC 95 %]	Valor real
2024Q1	21,481 [21,259; 21,706]	21,250
2024Q2	22,015 [21,556; 22,481]	21,685
2024Q3	22,291 [21,588; 22,999]	21,823
2024Q4	22,331 [21,393; 23,311]	21,858

Tabla 7.2.11: Predicción de la serie de ocupados para 2024 (en logaritmos y en miles de personas).

7.3. Serie temporal de parados

En cuanto al nivel de parados, la modelización tiene como objetivo predecir su evolución para los cuatro trimestres del año 2024. Tras el proceso de identificación, el modelo seleccionado es un $SARIMAX(1,1,0) \times (0,1,2,4)$. Al igual que en la serie de ocupados, la inspección visual de los datos originales (gráfico 7.3.1) sugiere la necesidad de estabilizar la varianza y la media.




Gráfico 7.3.1: Descomposición de la serie de parados original, y_t .

Para ello, se aplicó una transformación logarítmica seguida de una diferencia regular y una estacional (gráfico 7.3.2).




Gráfico 7.3.2: Descomposición de la serie de parados transformada, $(1 - B)(1 - B^4) \log(y_t)$.

El análisis de los correlogramas simple y parcial (gráfico 7.3.3) es determinante para identificar la estructura autorregresiva regular y de medias móviles estacionales del modelo final.




Gráfico 7.3.3: Funciones de auto correlación simple (ACF) y parcial (PACF) de $(1 - B)(1 - B^4) \log(y_t)$.

Un componente crítico de este modelo es el tratamiento de los eventos exógenos mediante análisis de intervención. Se detectaron cinco fechas clave que distorsionaban la estacionariedad: el tercer trimestre de 2005, el inicio de la crisis financiera en 2009 (Q1), la pandemia en 2020 (Q3) y los periodos de recuperación en 2021 (Q4) y 2023 (Q2). A diferencia de la serie de ocupados, todas estas intervenciones se modelizaron como impulsos con recuperación gradual o «Cambio Temporal» (*Time Change*), con un factor de decaimiento geométrico $\delta \approx 0,7$. Al trabajar en doble diferencia, el regresor que entra en la estimación es $x_T = \Delta \Delta_4 I_t = (1 - B)(1 - B^4) I_t(T_0, \delta)$, donde $I_t(T_0, \delta) = 0$ si $t < T_0$ y δ^{t-T_0} si $t \geq T_0$. La estimación ofrece una lectura económica coherente: el coeficiente asociado a 2009Q1 es positivo (0,0682),

reflejando el repunte transitorio del desempleo al inicio de la crisis financiera; de igual forma, el *shock* de la pandemia en 2020Q3 muestra un coeficiente positivo (0,0835), indicando un aumento abrupto del paro que se reabsorbe gradualmente. Por el contrario, los coeficientes para 2005Q3, 2021Q4 y 2023Q2 presentan signos negativos, interpretados como reducciones transitorias del desempleo.

	ar1	sma1	sma2	TC_2005:03	TC_2009:01	TC_2020:03	TC_2021:04	TC_2023:02
Coefficiente	0,7474	-0,6699	-0,2726	-0,0648	0,0682	0,0835	-0,0876	-0,0879
(s.e.)	(0,0809)	(0,2229)	(0,1605)	(0,0180)	(0,0175)	(0,0182)	(0,0190)	(0,0195)

Tabla 7.3.4: Estimaciones de los coeficientes del modelo identificado SARIMAX(1,1,0)×(0,1,2,4).

La bondad del ajuste queda respaldada por los estadísticos presentados en las tablas 7.3.5 y 7.3.6.

sigma ²	log likelihood	AIC	AICc	BIC
0,0007806	179,45	-340,89	-338,43	-319,12

Tabla 7.3.5: Estadísticos del modelo identificado SARIMAX(1,1,0)×(0,1,2,4).

ACF1	ME	RMSE	MAE	MPE	MAPE	MASE
-0,002148258	0,02579284	0,01905993	-0,06397101	1,827949	0,1616501	-0,07656195

Tabla 7.3.6: Medidas de ajuste de la muestra de entrenamiento.

Aunque el modelo presenta un RMSE reducido (0,019) y un MAPE del 0,16 en la muestra de entrenamiento, el diagnóstico de los residuos revela un matiz importante.




Gráfico 7.3.7: Cuadro resumen de diagnóstico de los residuos del modelo 7.3.4. Nota: la primera fila muestra la ACF y PACF de los residuos; la segunda, la de los residuos al cuadrado; la tercera, el

QQ-plot y el gráfico de densidad de los residuos frente a la normal, incluyendo el test semiparamétrico de Jarque-Bera como leyenda.

Si bien los contrastes de Ljung-Box (tabla 7.3.8) confirman la ausencia de autocorrelación serial –permitiendo calificar a los residuos como ruido blanco–, el test de Jarque-Bera y el análisis visual indican que no siguen una distribución normal. Esta falta de gaussianidad sugiere cautela en la interpretación de los intervalos de confianza, aunque no invalida la capacidad predictiva puntual del modelo.

Lag	Residuos		Resid. al cuad.		Lag	Residuos		Resid. al cuad.	
	Q	p	Q	p		Q	p	Q	p
1	0.50415	–	0.22978	0.63160	19	12.31213	0.72223	13.06309	0.83533
2	1.37275	–	2.53792	0.28112	20	12.35482	0.78179	13.20814	0.86880
3	1.58626	0.00000	9.57838	0.02251	21	14.56440	0.67163	13.73064	0.88099
4	1.60480	0.40522	9.64877	0.04678	22	14.82549	0.73362	14.58146	0.87957
5	1.64134	0.44214	10.45835	0.06372	23	15.53252	0.74517	14.72637	0.90417
6	1.64347	0.46957	10.48567	0.10563	24	15.77453	0.78128	14.89805	0.92371
7	3.50725	0.47678	10.49720	0.16210	25	16.06151	0.81282	15.28778	0.93440
8	3.71047	0.59181	10.51127	0.23096	26	16.09500	0.85117	15.59629	0.94543
9	3.71298	0.71545	10.51689	0.31028	27	17.12299	0.84337	15.97133	0.96020
10	3.71925	0.81149	10.55375	0.39332	28	17.95833	0.84415	15.69610	0.97011
11	3.82740	0.87235	10.59266	0.47799	29	18.29095	0.86493	15.92409	0.97638
12	3.97103	0.91331	10.63199	0.56069	30	18.58174	0.88474	16.17509	0.98121
13	5.14732	0.88112	11.34335	0.58208	31	18.61439	0.90961	16.18233	0.98862
14	5.23372	0.91932	11.47333	0.64852	32	18.62867	0.93044	16.75052	0.98778
15	9.45020	0.66407	11.73378	0.69060	33	18.69888	0.94609	16.96029	0.99057
16	11.24995	0.58989	12.16697	0.73241	34	19.28177	0.94998	16.98655	0.99340
17	11.35894	0.65764	12.44713	0.77234	35	19.59124	0.95800	17.21317	0.99440
18	11.36573	0.71156	12.47505	0.82177	36	19.62398	0.96840	17.72574	0.99543

Tabla 7.3.8: Contraste conjunto de Ljung-Box para residuos y residuos al cuadrado (modelo 7.3.4).

Finalmente, las proyecciones para 2024 (gráfico 7.3.10) comparan los valores predichos, re-transformados a miles de personas, con los datos reales observados. El modelo demuestra una alta precisión a corto plazo, especialmente en el primer trimestre de 2024, donde la predicción puntual de 2.978,2 miles de parados es prácticamente idéntica al valor real de 2.977,9 miles. A medida que avanza el horizonte hacia el cuarto trimestre se observa una ligera divergencia entre la predicción (2.691,3 miles) y el dato real (2.595,5 miles), aunque el valor observado se mantiene dentro de los amplios intervalos de confianza.




Gráfico 7.3.10: Gráfico de predicción de la serie en logaritmos de los 4 trimestres de 2024.

Periodo	Predicción (log)	Intervalo de confianza (95 %)
2024Q1	1,0913440	[1,0362145; 1,146473]
2024Q2	1,0310282	[0,9200868; 1,141969]
2024Q3	1,0021620	[0,8335175; 1,170806]
2024Q4	0,9900409	[0,7643678; 1,215714]

Periodo	Predicción real [IC 95 %]	Valor real
2024Q1	2,978,2 [2,818,6; 3,147,1]	2,977,9
2024Q2	2,804,0 [2,510,8; 3,132,9]	2,755,3
2024Q3	2,724,2 [2,301,4; 3,224,4]	2,754,1
2024Q4	2,691,3 [2,147,6; 3,372,6]	2,595,5

Tabla 7.3.10: Predicción de la serie de parados para 2024 (en logaritmos y en miles de personas).

7.4. Serie temporal de tasa de paro

Finalmente, derivamos la tasa de paro combinando las predicciones de ocupados y parados (c) y la comparamos con la predicción de la tasa modelizada directamente (nc). Los resultados se recogen en la tabla 7.4.

Periodo	Tasa de paro (c) [IC 95 %]	Tasa de paro (nc)
2024Q1	12,1765 [11,4928; 12,8946]	12,3961
2024Q2	11,2975 [10,0412; 12,6888]	11,6752
2024Q3	10,8901 [9,0902; 12,9955]	11,3650
2024Q4	10,7557 [8,4359; 13,6122]	11,1385

Tabla 7.4: Tasa de paro de 2024 derivada de las predicciones de ocupados y parados (c) frente a la tasa modelizada directamente (nc).

Conclusión

En este artículo se ha desarrollado un marco de análisis trazable y matemáticamente fundamentado para modelos de series temporales univariantes centrados en la media condicional, en la tradición de Box y Jenkins (1976). Partiendo de la premisa de que los datos empleados en

investigación económica para vez son replicables, resulta necesario recurrir a una estructura probabilística que discipline y simplifique la estimación. Bajo el supuesto de estacionariedad débil, se han presentado los procesos estacionarios fundamentales –Ruido Blanco, $MA(q)$ y $AR(p)$ – como distintas configuraciones de memoria temporal. En este marco, el teorema de descomposición de Wold actúa como puente teórico que justifica el uso de modelos ARMA para aproximar la componente no determinista, así como sus extensiones con estacionalidad, $SARIMA(p, d, q) \times (P, D, Q, S)$, y con regresores exógenos adicionales, $SARIMAX(p, d, q) \times (P, D, Q, S)$.

Más que la predicción en sí misma, lo verdaderamente relevante es el método que conduce a ella: construir un modelo transparente, interpretable y estadísticamente validado. Cuando la metodología es sólida, la predicción emerge como consecuencia natural, y su incertidumbre puede cuantificarse y comunicarse de forma rigurosa.

La aplicación de esta metodología al mercado laboral español ha requerido transformar las series mediante logaritmos y diferencias, e incorporar variables de intervención para capturar *shocks* extraordinarios como la crisis financiera de 2008 y la pandemia de COVID-19. En el caso de los ocupados, el modelo $SARIMAX(1,1,0) \times (2,1,1,4)$ ofrece un ajuste robusto con residuos aproximadamente gaussianos. En el de los parados, el modelo $SARIMAX(1,1,0) \times (0,1,2,4)$ presenta mayores dificultades para alcanzar la normalidad, aunque captura la estructura de la media con suficiente precisión como para sustentar predicciones prudentes. Finalmente, se comprueba que derivar la tasa de paro a partir de las identidades económicas –combinando las previsiones de ocupados y parados– produce pronósticos más coherentes e interpretables que modelizar la tasa directamente.

Bibliografía

- Bartlett, M. S. (1946). On the Theoretical Specification and Sampling Properties of Auto-correlated Time-Series. *Supplement to the Journal of the Royal Statistical Society*, 8(1), 27–41.
- Box, G. E. P., & Jenkins, G. M. (1976). *Time series analysis: Forecasting and control*. Holden-Day.
- Brockwell, P. J., & Davis, R. A. (2002). *Time Series: Theory and Methods*. Springer.
- Casals, J., Garcia-Hiernaux, A., Jerez, M., Sotoca, S., & Trindade, A. A. (2016). *State-Space Methods for Time Series Analysis: Theory, Applications and Software*. Chapman and Hall/CRC.
- Cryer, J. D., & Chan, K.-S. (2008). *Time Series Analysis: With Applications in R*. Springer.
- García Delgado, J. L., & Myro Sánchez, R. (Dirs.). (2019). *Lecciones de Economía Española*. Thomson Reuters Aranzadi.
- Hamilton, J. D. (1994). *Time series analysis*. Princeton University Press.
- Ljung, G. M., & Box, G. E. P. (1978). On a Measure of Lack of Fit in Time Series Models. *Biometrika*, 65(2), 297–303.
- Monti, A. C. (1994). A proposal for a residual autocorrelation test in linear models. *Biometrika*, 81(4), 776–780.
- Peña, D. (2010). *Análisis de series temporales*. Alianza Editorial.
- Wold, H. (1954). *A study in the analysis of stationary time series* (2nd ed.). Almqvist & Wiksell.

A. El contraste de raíz unitaria de Dickey-Fuller

El proceso estocástico de Paseo Aleatorio (PA) es un caso concreto de AR(1) en el que $\phi_1 = 1$. Este tipo de procesos tiene raíz unitaria y, por tanto, no es estacionario en sentido débil. La prueba estadística de Dickey-Fuller permite discriminar si un proceso autorregresivo $\{y_t\}_{t=1}^T$ es estacionario, $y_t \in I(0)$, o si, por el contrario, no lo es, $y_t \in I(1)$. De inicio sabemos que tenemos un modelo AR(1),

$$y_t = c + \rho y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim RBG(0, \sigma^2),$$

en el que si $|\rho| < 1$ el proceso es estacionario, $I(0)$, y si $\rho = 1$ aparece la raíz unitaria y, por tanto, no es estacionario, $I(1)$. Una vez estimados los parámetros del modelo $(\hat{c}, \hat{\rho}, \hat{\varepsilon}_t, \hat{\sigma}_\varepsilon^2)$, el estadístico de contraste se construye como el cociente entre la desviación de $\hat{\rho}$ respecto a la unidad y su error estándar, $t = \frac{\hat{\rho}-1}{S(\hat{\rho})}$. La idea es estimar ρ y evaluar si su valor es compatible con $\rho = 1$ (raíz unitaria) o si es estrictamente menor que uno (estacionariedad). Este planteamiento puede expresarse de forma equivalente mediante las siguientes hipótesis:

$$H_0 : (1 - B) y_t = \varepsilon_t, \quad H_1 : (1 - \rho B) y_t = c + \varepsilon_t.$$

Bajo la hipótesis nula, $\rho = 1$, el modelo se encuentra en la frontera de la estacionariedad. En esta situación, la varianza del proceso no está acotada y el estadístico t asociado a $\rho = 1$ no sigue una distribución t-Student estándar. Pequeñas variaciones en el valor del parámetro ρ en torno a la unidad implican cambios sustanciales en el comportamiento de la varianza, pasando de ser infinita a finita cuando el proceso deja de ser un paseo aleatorio. Esto hace que el estadístico del contraste no converja a una distribución límite estándar, lo que impide utilizar los valores críticos habituales de la t-Student. Por esta razón es necesario recurrir al enfoque de Dickey-Fuller, cuya distribución bajo la hipótesis nula es no estándar y debe obtenerse mediante tabulación específica.

Para subsanar esta inconsistencia hacemos una reparametrización del modelo base, restándole a los dos lados de la ecuación lo mismo, con lo que nos queda un modelo equivalente al de base:

$$y_t - y_{t-1} = c + (\rho - 1) y_{t-1} + \varepsilon_t.$$

Definimos la primera diferencia, $\Delta y_t \equiv y_t - y_{t-1} = (1 - B) y_t$, y el nuevo parámetro, $\alpha \equiv \rho - 1$, con lo que se obtiene la regresión auxiliar en diferencias de Dickey-Fuller, en la que la variación de la serie depende del nivel retardado:

$$\Delta y_t = c + \alpha y_{t-1} + \varepsilon_t.$$

Una vez identificado el modelo, las hipótesis del contraste pueden expresarse como:

$$H_0 : \alpha = 0 \Leftrightarrow \rho = 1 \Rightarrow y_t \in I(1), \quad H_1 : \alpha < 0 \Rightarrow y_t \in I(0).$$

Ahora la desviación típica de este estimador sí se estima de forma robusta, con un estadístico t-Student bien definido $t = \frac{\hat{\alpha}}{SE(\hat{\alpha})}$. Sin embargo, bajo H_0 el proceso presenta raíz unitaria y, por tanto, no es estacionario, de modo que el estadístico t no converge a una distribución t-Student estándar, sino a una distribución límite no estándar, obtenida mediante tabulación, conocida

como la distribución de Dickey-Fuller, $t \mid H_0 \sim DF$. Dado que el contraste es unilateral, si el valor del estadístico t es suficientemente negativo, es decir, menor que el valor crítico de la distribución Dickey-Fuller, se rechaza la hipótesis nula de raíz unitaria, concluyendo que el proceso es estacionario. En caso contrario, no se rechaza H_0 y la serie es compatible con un proceso no estacionario.

Cuando tratamos con datos reales rara vez observamos un AR(1) puro. La serie puede presentar una dinámica autorregresiva de orden superior –AR(p)– o contener una parte de media móvil (MA). En estas circunstancias, la regresión auxiliar del Dickey-Fuller simple puede generar residuos autocorrelacionados, lo que invalida el contraste al incumplirse el supuesto de perturbaciones tipo ruido blanco. La idea del contraste de Dickey-Fuller Aumentado (ADF) es precisamente limpiar esa autocorrelación: en vez de suponer que toda la dinámica relevante queda capturada con y_{t-1} , añadimos p retardos de los incrementos Δy_t para absorber la dinámica de corto plazo que, de otro modo, quedaría en el término de error. Para garantizar que la perturbación sea aproximadamente no autocorrelacionada, el ADF estima la regresión auxiliar aumentada:

$$\Delta y_t = c + \alpha y_{t-1} + \sum_{i=1}^p \beta_i \Delta y_{t-i} + u_t, \quad u_t \sim RB(0, \sigma^2).$$

El primer modelo contempla un retardo, y nos estaríamos preguntando si es un PA, es decir, un ARI(1,1), o un AR(2):

$$\Delta y_t = c + \alpha y_{t-1} + \beta_1 \Delta y_{t-1} + u_t, \quad u_t \sim RB(0, \sigma^2).$$

El segundo modelo contempla dos retardos, y nos estaría diciendo si es un ARI(2,1) o un AR(3):

$$\Delta y_t = c + \alpha y_{t-1} + \beta_1 \Delta y_{t-1} + \beta_2 \Delta y_{t-2} + u_t, \quad u_t \sim RB(0, \sigma^2),$$

y así sucesivamente. El número p de retardos a especificar es preferible que sea grande, porque si el modelo de regresión auxiliar aumentada es en realidad un MA, eso es un AR(∞) y, por tanto, es preferible que se estime con suficiente estructura autorregresiva para absorber la autocorrelación de residuos. Los métodos para la elección del número de retardos considerados suelen basarse en métricas de ajuste predictivo de tipo bayesiano (BIC) y frecuentista (AIC).